장별 방법 선택의 성능 상한: 원화 기반 깎기와 생성 3D 사이

An Oracle Upper Bound on Per-Instance Method Selection between Drawing-Based Carving and Single-Image Generative 3D

art2real 원화3d · 2026년 9월

코드 · 데이터: 원화3d/실험_20260919 · 논문/생성선택

초록 3면 원화로부터 입체 원형을 복원하는 두 경로 — 실루엣 교집합을 깎는 기하 기반 방법과 단일 이미지 생성 3D 를 원화 실루엣으로 자르는 방법 — 은 사례에 따라 우열이 뒤바뀐다. 실물 캐릭터 28 종에서 생성 기반 판본은 17 종에서 기하 기반 판본을 능가하지만, 집계 지표인 중앙 IoU 는 0.741 에서 0.739 으로 오히려 감소한다. 이는 사례별로 더 나은 쪽을 선택하는 라우팅 기법의 전형적 동기이다. 본 논문은 그러한 선택기를 설계하기 전에, **정답을 관측할 수 있는 완벽한 선택기**가 도달하는 성능 상한을 먼저 측정한다. 사전 등록된 기준(중앙 IoU 향상 +0.020, 두 해상도 모두)에 대하여 상한은 격자 128 에서 +0.023 (0.741 → 0.764), 격자 192 에서 +0.017 (0.726 → 0.744) 에 그쳐 기준을 충족하지 못하였다. 이 상한은 무작위 선택기와는 뚜렷이 구별되지만(장 수를 맞춘 무작위 선택기가 이를 넘을 확률 0.0010), 그 크기가 작고 불안정하다 — 상한 전체가 28 종 가운데 4 종에서 발생하며, 한 사례를 제외하면 기준을 넘는 경우가 28 회 중 14 회에 그친다. 원인은 두 판본이 서로를 보완하지 않는다는 데 있다. 사례별 점수의 상관은 0.935 이며, 두 판본의 점수를 사례 사이에서 무작위로 짝지은 귀무 분포에서 상한 향상은 +0.037 로 실제 값보다 오히려 크다(0.995). 즉 두 경로는 같은 사례에서 함께 어려우며, 선택으로 회수할 상보성이 우연 수준에도 미치지 못한다. 따라서 이 벤치마크에서 사례별 선택기를 구축할 근거는 없으며, 후속 연구는 선택이 아니라 생성 판본이 속이 빈 구조에서 지는 원인을 직접 다루어야 한다.

핵심어 사례별 방법 선택 · 오라클 상한 · visual hull · 생성 3D · 사전 등록 판정

1 서론

2D 원화만을 보유한 IP 소유자가 입체 굿즈를 제작하려면 조형 원형이 필요하다. 본 연구의 기본 파이프라인은 학습이나 생성 모델 없이 세 장의 직교 원화에서 실루엣 교집합인 visual hull 을 구하고 판 분할과 단면 깊이 추정으로 내부를 깎아 원형을 얻는다. 이와 별도로, 단일 이미지 생성 3D 모델의 출력을 원화 3면 실루엣으로 자르고 빈 영역만 기하 기반 결과로 보충하는 경로를 구성할 수 있다. 두 경로는 서로 다른 사전 지식을 사용한다. 전자는 원화 실루엣만을, 후자는 생성 모델이 학습한 물체 형상 사전분포를 추가로 사용한다.

실물 캐릭터 28 종에 대한 평가에서 두 경로의 우열은 사례마다 갈린다. 생성 기반 판본은 17 종에서 기하 기반 판본보다 높은 IoU 를 얻지만, 집계 지표인 중앙 IoU 는 0.741 에서 0.739 으로 감소한다. 이기는 사례와 지는 사례의 편차가 모두 크기 때문에 중앙값이 어느 쪽으로도 이동하지 않는 것이다. 이러한 상황은 사례별로 더 나은 방법을 고르는 **알고리즘 선택** 또는 **라우팅** 기법의 고전적 동기에 해당한다.

그러나 사례별 선택기는 평가 집합의 크기와 같은 수의 이진 자유도를 새로 도입한다. 본 연구의 벤치마크는 28 종이므로 선택기는 28 비트를 자유롭게 사용할 수 있고, 이 자유도만으로도 집계 지표가 상당히 움직인다. 따라서 선택기를 설계하고 그 성능을 보고하는 순서는 결론을 과대평가하기 쉽다.

본 논문은 순서를 뒤집는다. 선택 신호를 설계하기 전에 **정답 IoU 를 관측할 수 있는 완벽한 선택기**가 도달하는 성능 상한을 먼저 측정하고, 그 상한을 사전에 등록한 기준 및 무작위 선택기 분포와 비교한다. 기여는 다음과 같다.

1. 두 복원 경로 사이의 사례별 선택 문제에 대한 오라클 상한을 정의하고, 그 상한이 집계 지표에서 +0.023 (격자 128) 및 +0.017 (격자 192) 에 불과하며 소수 사례에 집중되어 불안정함을 보인다.
2. 두 판본의 점수를 사례 사이에서 짝을 섞은 귀무 분포를 대조군으로 두어, 실제 상보성이 우연 수준보다 **낮음**을 보인다. 이것이 상한이 낮은 기전이다.
3. 그 결과로 선택기 구축을 중단하고, 두 경로가 함께 실패하는 사례군의 원인을 직접 다루도록 후속 연구 방향을 수정한다.

2 관련 연구

사례별 알고리즘 선택. 입력 인스턴스의 특징으로부터 후보 알고리즘 중 하나를 고르는 문제는 Rice [1] 가 형식화한 이래 메타학습 분야에서 다루어져 왔으며, 특징 추출기와 선택 모형의 설계를 중심으로 정리되어 있다 [2]. 언어 모델 분야에서는 강한 모형과 약한 모형 사이의 질의 단위 라우팅이 비용–성능 절충으로 제시되었다 [3]. 이들 연구는 선택기의 설계와 학습에 초점을 두며, **선택 가능한 향상의 상한**을 사전에 측정하는 절차는 표준적으로 포함하지 않는다.

선택적 예측. 예측을 거부할 수 있는 분류기는 위험–포괄률(risk–coverage) 곡선으로 평가된다 [4], [5]. 본 문제에서 "거부"는 기하 기반 판본으로 되돌아가는 것에 해당하므로 같은 틀을 적용할 수 있다. 다만 본 논문은 곡선의 형태를 논하기 이전 단계, 즉 포괄률 100% 에서의 오라클 성능이 기준선과 구별되는지를 먼저 묻는다.

3면 원화 기반 복원. 실루엣 교집합으로 얻는 visual hull [6] 은 관측 실루엣의 상한이라는 성질을 가지며, 본 연구의 기하 기반 판본은 이를 판 분할과 단면 깊이로 깎는다.

단일 이미지 생성 3D 와 얇은 구조. 본 연구가 사용하는 생성 모형 [7] 은 점유 표현 대신 부호 거리장을 채택한 이유와 함께 그 한계를 명시한다 — “thin-shell structures where performance may worsen”. 같은 논문은 학습 데이터 구성 단계에서 관측 불가능한 격자의 거리값을 재설정하고 내부 메시 성분을 제거하여 **내부 구조를 지운** 필드를 학습한다고 기술한다. 의복 복원 연구 [8] 는 그 원인을 표현 수준에서 설명한다. 열린 곡면을 부호 거리장으로 표현하려면 “one has to wrap around them a watertight surface with a minimum thickness, which reduces accuracy” 이며, 부호 없는 거리장을 쓰면 표면 값이 정확히 0 이 되지 않아 구멍이 생긴다. 점유 표현 역시 안과 밖이 정의되어야 성립한다 [9]. 한편 얇은 구조를 표면 기반 방법으로 포착하려면 매우 높은 격자 해상도가 필요하다고 보고되어 있다 [10].

즉 망토나 치마에 대하여 생성 모형이 안쪽 면을 가진 껍질을 내놓는 것은 고장이 아니라 그 표현과 학습 데이터의 정상적인 귀결이다. 본 연구의 평가 정답은 수평 단면마다 닫힌 영역을 채운 것이므로, 그 껍질은 그대로 감점으로 계산된다. 이 점은 5.3절의 방향 설정에서 다시 다룬다.

3 방법

3.1 두 판본

비교 대상은 표 1 의 두 판본이다. 두 판본은 동일한 원화 입력, 동일한 창 좌표, 동일한 복셀 격자에서 구성된다.

표 1. 비교 판본. 두 판본 모두 정답을 참조하지 않고 구성된다.

판본	설명
B 기하 기반	원화 3면 실루엣 교집합을 판 분할과 타원 단면 깊이로 깎은 원형. 기본 파이프라인
G 생성 기반	단일 이미지 생성 3D 출력을 원화 3면에 정합한 뒤 실루엣 교집합으로 자르고, 원화 실루엣이 비는 화소에 한하여 B 로 보충한 원형

평가 지표는 수평 단면마다 닫힌 영역을 채운 정답에 대한 3D IoU 이며, 복셀 격자 128 과 192 의 두 해상도에서 각각 계산한다. 이 지표와 정답 구성은 선행 연구에서 확정된 것을 변경 없이 사용한다.

3.2 오라클 상한

사례 집합을 $\mathcal{C}$, 사례 c 의 두 판본 점수를 B_c, G_c 라 하자. 선택기는 함수 $s : \mathcal{C} \to \{B, G\}$ 이며, 그 집계 성능은 사례별 점수의 중앙값이다.

$$M(s) = \mathrm{med}_{c \in \mathcal{C}}[s(c)_c] \tag{1}$$

완벽한 선택기 s^* 는 정답을 관측하여 사례마다 큰 쪽을 고른다.

$$s^*(c) = \arg\max_{v \in \{B,G\}} v_c, \quad M(s^*) = \mathrm{med}_c[\max(B_c, G_c)] \tag{2}$$

$M(s^*)$ 는 어떤 선택기도 넘을 수 없는 상한이다. 상한 향상량을 $\Delta^* = M(s^*) - M(B)$ 로 정의하고, 임의의 선택기 s 에 대한 **상한 회수율**을 다음과 같이 둔다.

$$\rho(s) = \frac{M(s) - M(B)}{\Delta^*} \tag{3}$$

정의에 따라 $\rho(s^*) = 1$, $\rho(B) = 0$ 이다. 신호 기반 선택기는 $\rho < 1$ 이므로, Δ^* 가 작으면 실현 가능한 향상은 그보다 더 작다.

3.3 사전 등록된 판정 기준

실험 이전에 다음을 등록하였다. 상한 향상량 Δ^* 가 격자 128 과 192 **모두에서** 0.020 이상이고, 중앙차의 95% 부트스트랩 구간이 0 을 포함하지 않을 때에만 선택 신호의 설계로 진행한다. 두 조건 중 하나라도 어기면 그 자리에서 중단하고 음성 결과를 보고한다.

기준값 0.020 의 근거는 다음과 같다. 신호 기반 선택기는 회수율 $\rho < 1$ 이므로 실현 향상은 Δ^* 의 일부에 그친다. 또한 사례 수가 28 이므로 중앙값은 순위 14위와 15위 사례가 결정하며, 사례 하나가 자리를 바꾸는 것만으로도 이와 비슷한 폭이 움직인다. 즉 Δ^* 가 이 값에 미치지 못하면 파이프라인에 새 구성 요소를 추가할 근거가 되지 않는다.

3.4 대조군

사례별 선택기는 $|\mathcal{C}|$ 비트의 자유도를 새로 얻는다. 이 자유도 자체가 만드는 변동을 측정하기 위해 다음 대조군을 둔다.

언제나 B $M(B)$. 기준선.

언제나 G $M(G)$. 선택 없이 생성 판본만 사용.

무작위 선택기 R 사례마다 독립적으로 동전을 던져 고른다.

장 수 맞춤 무작위 선택기 R_k 완벽한 선택기가 G 로 돌린 사례 수 k 를 그대로 주고, **어느 사례인지만** 무작위로 정한다. 이득이 “몇 사례를 G 로 돌렸는가”에서 오는지 “어느 사례를 골랐는가”에서 오는지를 가른다.

짝 섞기 귀무분포 G 의 사례별 점수를 사례 사이에서 무작위로 치환하여 B 와 짝지은 뒤 식 식 2 의 상한을 계산한다. 이는 **두 판본의 난이도가 서로 독립일 때** 최댓값 연산만으로 발생하는 상한 향상이며, 실측값이 이보다 낮다면 두 판본이 같은 사례에서 함께 실패한다는 뜻이다.

세 대조군 모두 2000 회 재표본한다. 앞의 둘은 **정보를 사용하지 않는 선택기가 얻는 성능**을, 셋째는 **선택할 상보성이 애초에 존재하는가**를 묻는다.

4 실험

4.1 재현성 검사

판정에 사용한 점수는 새로 계산하지 않고 선행 평가 기록에서 읽었다. 기록된 기하 기반 판본의 중앙 IoU 가 공표된 값 0.7413 (격자 128) 및 0.7265 (격자 192) 와 10^{-4} 이내에서 일치함을 확인하였고, 사례 집합이 28 종으로 동일함을 확인하였다. 또한 상한이 정의상 $\max(B_c, G_c)$ 임을 모든 사례에서 검사하였다.

4.2 결과

표 2 에 상한 측정 결과를 제시한다.

표 2. 사례 28 종에 대한 집계 성능. 향상은 기준선 B 대비 중앙 IoU 의 차이이다. 사전 등록된 통과 기준은 상한 향상 0.020 이상이다.

판본 · 선택기	중앙 IoU (128)	향상	중앙 IoU (192)	향상
B 기하 기반 (기준선)	0.741	–	0.726	–
G 생성 기반	0.739	−0.003	0.718	−0.009
R 무작위 선택기 (중앙)	0.739	−0.003	0.719	−0.007
R 무작위 선택기 (97.5 분위)	0.755	+0.013	0.738	+0.012
s^* 완벽한 선택기 (상한)	**0.764**	**+0.023**	**0.744**	**+0.017**

상한 향상은 격자 128 에서 +0.023, 격자 192 에서 +0.017 이다. 격자 192 는 사전 등록 기준 0.020 에 미달한다. 격자 128 은 점 추정값으로는 기준을 충족하나, 사전 등록한 둘째 조건인 중앙차의 95% 부트스트랩 구간이 [0.0000, 0.0344] 로 0 을 포함하여 이를 충족하지 못한다. 격자 192 의 구간도 [0.0000, 0.0283] 로 동일하다. 다만 이 둘째 조건은 본 문제에서 사실상 부호검정으로 퇴화하므로(5.1절), 결론은 점 추정에 기초한 첫째 조건으로만 해석한다. 그 경우 해상도 간 판정이 엇갈리며, 사전 등록된 규칙에 따라 어느 쪽으로도 결론을 채택하지 않는다.

상한은 소수 사례에 집중되어 있다. 사례를 실제 이득 순으로 정렬하여 상위 k 개만 G 로 돌릴 때의 집계 향상을 계산하면, 상한 전체가 4 개 사례에서 달성되고 이후로는 증가하지 않는다. 한 사례를 제외하고 상한 향상을 다시 계산하면 격자 128 에서 +0.0163 에서 +0.0295 사이에서 변동하며, 28 회 중 14 회만 사전 등록 기준을 넘는다. 격자 192 에서는 14 회이다. 즉 상한은 특정 소수 사례에 의존한다.

4.3 자유도 대조군과 상보성

정보를 사용하지 않는 선택기와 비교하면 상한은 뚜렷이 구별된다. 동전 던지기 선택기가 상한 향상 이상을 얻을 확률은 격자 128 에서 0.0020, 장 수를 완벽한 선택기와 맞춘 R_k ($k = 17$) 의 경우 0.0010 이다. R_k 의 이득 중앙값은 −0.003 로 0 근처이며 95% 구간은 [−0.0168, +0.0076] 이다. 따라서 **상한이 자유도만으로 얻어진다는 해석은 성립하지 않는다.** 상한이 작은 것은 우연의 크기 때문이 아니라 다른 이유이다.

그 이유는 짝 섞기 귀무분포가 보인다. 표 3 과 같이, 두 판본의 점수를 사례 사이에서 무작위로 짝지으면 상한 향상은 격자 128 에서 +0.037, 격자 192 에서 +0.038 이 되어 **실측값보다 크다**. 실측 상한이 이 귀무분포 이하일 확률은 각각 0.995 과 0.999 이다.

표 3. 상보성 검정. 두 판본의 난이도가 독립이라면 최댓값 연산만으로 귀무분포 수준의 향상이 발생한다. 실측값은 이보다 낮다.

상한 향상 Δ^*	격자 128	격자 192
실측 (실제 짝)	**+0.0229**	**+0.0174**
짝 섞기 귀무분포 (중앙)	+0.0375	+0.0380
짝 섞기 95% 구간 하한	+0.0246	+0.0250
P(귀무 ≥ 실측)	0.995	0.999
두 판본 점수의 상관 r	0.935	0.927

두 판본의 사례별 점수는 상관 0.935 (격자 128) 로 강하게 연동되어 있다. 한쪽이 어려워하는 사례는 다른 쪽도 어려워한다. 사례별 선택이 이익을 내려면 두 방법이 서로 다른 사례에서 실패해야 하는데, 본 문제에서는 그 조건이 성립하지 않으며 오히려 우연보다도 덜 성립한다. 이것이 상한이 낮은 기전이다.

4.4 선택 대상의 범위

상한을 판본 두 개로 제한한 것이 결과를 좌우하지 않음을 확인하였다. 생성 경로의 중간 판본(실루엣 교집합만 적용하고 보충하지 않은 것)과 정합만 수행한 원 생성 출력을 포함하여 판본 네 개 사이에서 완벽하게 선택하더라도, 상한 향상은 격자 128 에서 +0.0232 로 두 판본일 때의 +0.0229 에서 +0.0003 만큼만 증가하며, 격자 192 에서는 +0.0174 로 변화가 없다.

4.5 사례별 양상

그림 1 는 생성 판본이 크게 지는 사례 넷과 크게 이기는 사례 넷을 정답과 나란히 제시한다. 생성 판본이 크게 지는 사례는 `cloak_Cloche_Qz9XMYysBQ`, `hairsample_female`, `avatarsample_e`, `knight_Warrior_Z6ZUtm6kc1` 이며, 이 가운데 `hairsample_female` 와 `avatarsample_e` 는 머리카락과 치마처럼 원본 메시에서 두께가 거의 없는 곡면으로 구성된 구조이다. 단일 이미지 생성 모델은 이러한 구조를 안쪽 면을 가진 껍질로 복원하며, 실루엣 교집합으로 자르는 연산은 깎기만 하므로 그 빈 내부를 회복하지 못한다. 크게 이기는 사례는 `mech_Drill_8uBbH7Dvmb`, `sendagaya_shino`, `wizard_Wizard_o87Upt5uHX`, `wizard_WIzard_Gnome_dEuyzEgrF4` 로, 기계 · 로봇 · 인체형과 같이 내부가 채워진 부피를 갖는 물체이다.

다만 이 시각적 설명은 척도로 옮겨지지 않는다. 위 가설을 직접 겨냥하여 두 판본의 점유 부피비 $|G| / |B|$ 를 28 종 전부에서 측정하였으나, 사례별 이득과의 순위 상관은 −0.107 으로 무의미하며 중앙값도 생성이 지는 사례군 0.882 과 이기는 사례군 0.878 이 사실상 같다. 실제로 가장 크게 지는 `cloak_Cloche_Qz9XMYysBQ` 의 부피비는 1.217 로 생성 판본이 오히려 더 크다 — 이 사례의 손실은 내부가 비어서가 아니라 그림 1 에서 보이듯 반구형 정답을 상자형으로 복원한 형상 오류에서 온다. 즉 "속이 비었다"는 서술은 일부 사례를 설명하지만 우열을 가르는 척도가 아니며, 이는 5.2절에서 어떤 기존 량도 선택 신호가 되지 못한 것과 같은 맥락이다.

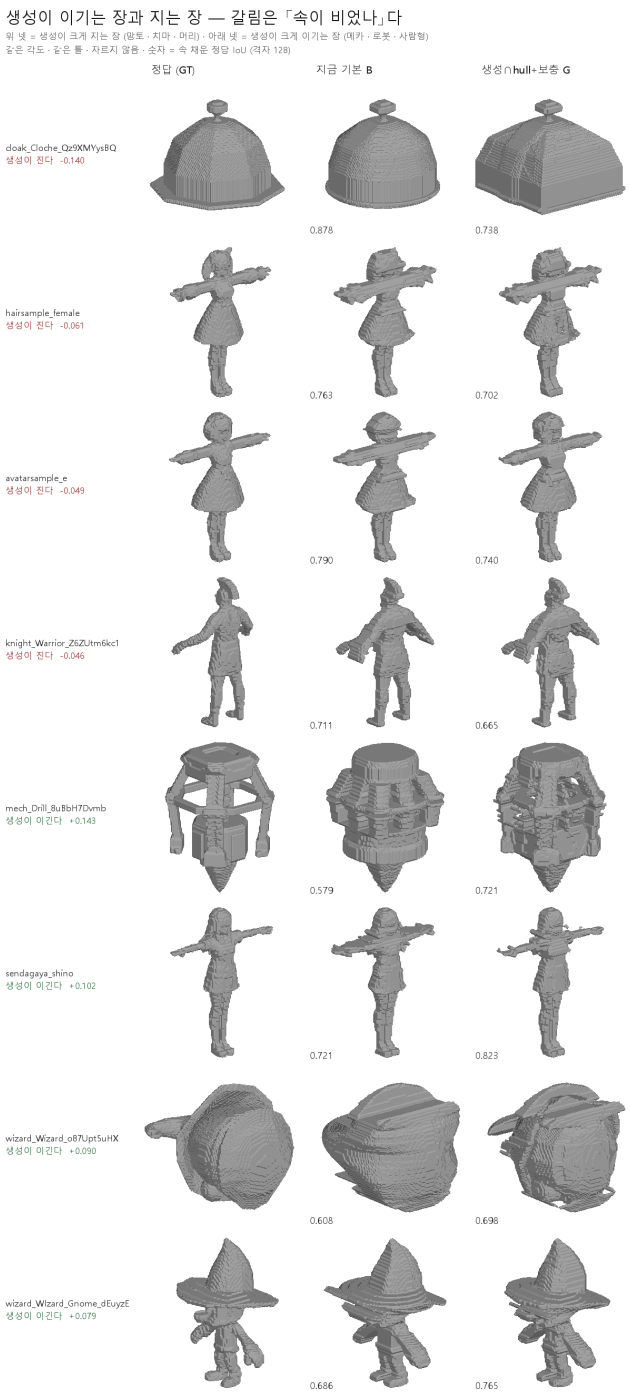


그림 1. 생성 판본이 크게 지는 사례 넷(위)과 크게 이기는 사례 넷(아래). 왼쪽부터 정답, 기하 기반 B, 생성 기반 G 이며 숫자는 격자 128 의 IoU 이다. 지는 사례는 대부분 속이 빈 구조이나, 맨 위 사례는 반구형 정답을 상자형으로 복원한 형상 오류이다.

이 양상은 상한이 낮은 이유도 설명한다. 두 판본의 우열이 갈리는 사례는 17 종이지만, 중앙값을 결정하는 순위 중앙 부근의 사례는 `avatarsample_g` 와 `robot_Robot_ejDr8lRglP` 이며, 완벽한 선택으로 값이 바뀌는 사례는 17 종에 그친다. 중앙값은 극단적으로 이기는 사례의 크기를 반영하지 않으므로, 사례별 선택이 개선하는 것은 주로 분포의 하단이고 집계 지표는 거의 움직이지 않는다.

5 논의

5.1 결론의 범위

본 실험의 결론은 **이 벤치마크의 이 집계 지표** 에 한정된다. 사례별 차이는 최대 +0.143 에서 −0.140 에 이르는 데 비해 중앙값은 그 차이를 흡수한다. 집계 함수를 바꾸면 판정이 달라진다 — 상한 향상을 평균으로 계산하면 격자 128 에서 +0.0275, 격자 192 에서 +0.0260 로 **두 해상도 모두 사전 등록 기준을 넘는다**. 반대로 최악 사례 기준으로는 +0.0084 및 +0.0041 로 미미하다. 본 연구의 집계 지표는 선행 결정에 따라 중앙 IoU 로 고정되어 있으므로 본 실험은 그 지표에 대해 답하지만, 평균을 제품 지표로 채택한다면 이 결론은 재검토되어야 한다. 다만 4.3절의 상보성 결과는 집계 함수와 무관하게 성립한다.

사전 등록한 두 조건 중 두 번째, 즉 중앙차의 신뢰구간이 0 을 포함하지 않을 것이라는 조건은 본 문제에서 검정력이 약하다는 점을 명시한다. $\max(B_c, G_c) - B_c$ 는 정의상 음이 아니므로 이 구간의 하한은 0 보다 작아질 수 없고, 판별력은 사실상 “0 인 사례가 얼마나 많은가”에서만 나온다. 본 실험에서 기하 기반 판본이 이긴 11 개 사례가 정확히 0 을 기여하므로 구간 하한이 0 이 되었다. 따라서 이 조건은 상한이 0 이라는 증거가 아니라, 표본이 이 크기일 때 상한을 0 과 분리하기 위한 사례 수가 부족하다는 지시로 읽어야 한다. 점 추정에 기초한 첫 번째 조건만을 적용하면 격자 128 은 통과하고 격자 192 는 미달하여 해상도 간 판정이 엇갈리며, 사전 등록된 규칙에 따라 이 경우에도 결론을 채택하지 않는다. 두 해석 모두 선택기를 구축하지 않는다는 동일한 행동으로 귀결되나, 전자가 더 강한 주장이고 후자가 더 약한 주장이다. 본 논문은 약한 쪽을 근거로 삼는다.

또한 사례 수 28 은 중앙값 기반 판정에 대한 검정력이 낮다. 중앙차의 부트스트랩 구간이 두 해상도 모두 0 을 포함한 것은 상한이 0 이라는 뜻이 아니라, 이 표본 크기로는 상한을 0 과 분리할 수 없다는 뜻이다. 표본을 확대하면 상한 향상이 유의해질 수 있으나, 그 경우에도 점 추정값은 여전히 +0.023 수준이므로 실현 향상은 그보다 작다.

5.2 신호 설계를 수행하지 않은 이유

사전 등록된 분기에 따라 신호 설계와 그 이득 측정은 수행하지 않았다. 근거는 세 가지이다. 첫째, 상한 향상이 사전 등록 기준에 미달하고 해상도 간 판정이 엇갈린다. 둘째, 상한이 4 개 사례에 집중되어 있어 한 사례를 제외하면 기준 통과 여부가 뒤집힌다(4.2절). 셋째이자 가장 중요한 이유로, 4.3절의 짝섞기 대조군이 **선택할 상보성 자체가 우연 수준 이하**임을 보인다. 신호를 아무리 잘 설계하더라도 존재하지 않는 상보성을 회수할 수는 없다.

이 판단은 이미 기록되어 있는 량으로도 확인된다. 선행 연구에서 정의된 표면 이상 지표와 두 판본의 실루엣 불일치 지표, 본 연구에서 추가한 원화 형상 지표를 포함한 22 개 량 가운데 사례별 이득 $G_c - B_c$ 와의 순위 상관이 가장 큰 것은 조각 로 $\rho = +0.327$ 이며, 나머지는 모두 이보다 작다. 더욱이 상관의 부호가 선택에 필요한 방향과 반대이다 — 분리된 조각이 많거나 표면 이상이 큰 사례일수록 생성 판본이 오히려 더 크게 이긴다. 이는 그러한 사례가 기하 기반 방법에게도 어려운 사례이기 때문이며, 4.3절이 보인 두 판본의 강한 양의 상

관과 같은 현상이다. 즉 기존 이상 지표는 후처리 호출 여부를 판단하는 데에는 쓰이더라도 경로 선택에는 쓸 수 없다.

5.3 다음 방향

성능 차이는 선택으로 회수할 수 있는 종류가 아니다. 두 경로는 같은 사례에서 함께 어려우며(4.3절), 그 공통의 어려움을 줄이지 않는 한 어느 쪽을 고르든 집계 지표는 거의 움직이지 않는다. 생성 판본이 특히 지는 사례군에 대해서는 2절이 검토한 표현 수준의 설명이 있다. 단일 이미지 생성 모델은 두께 없는 곡면을 최소 두께의 닫힌 곡면으로 감싸 안쪽 면을 만들며, 평가 정답은 수평 단면마다 닫힌 영역을 채운 것이므로 그 안쪽 면이 그대로 감점이 된다. 따라서 후속 연구는 선택이 아니라 생성 출력을 평가 정답과 동일한 단면 채움 규칙으로 메운 뒤 실루엣 교집합을 적용하는 방향을 다룬다. 이 방향은 평가 정답의 구성 규칙과 복원 규칙을 일치시키므로 원인에 직접 대응한다. 다만 4.5절이 보였듯 형상 오류로 지는 사례는 이 방향으로 개선되지 않으므로, 그 사례군은 별도로 다루어야 한다.

6 결론

두 복원 경로 사이의 사례별 선택에 대하여 완벽한 선택기가 도달하는 상한을 측정하였다. 상한 향상은 격자 128 에서 +0.023, 격자 192 에서 +0.017 으로 사전 등록된 기준 0.020 을 충족하지 못하였고, 상한 전체가 4 개 사례에서 발생하여 한 사례를 제외하면 기준 통과 여부가 뒤집힌다. 이 상한은 무작위 선택기와 뚜렷이 구별되므로 자유도만으로 설명되지는 않는다. 상한이 낮은 기전은 상보성의 부재이다 — 두 판본의 사례별 점수는 상관 0.935 로 연동되어 있으며, 짝을 섞은 귀무 분포에서의 상한 향상 +0.037 이 실측값보다 크다. 두 경로는 서로 다른 사례가 아니라 같은 사례에서 실패한다. 따라서 이 벤치마크에서 사례별 선택기를 구축할 근거는 없으며, 공통의 실패 원인을 줄이는 편이 선행되어야 한다. 이는 선택기를 설계한 뒤 성능을 보고하는 통상의 순서를 뒤집어, 상한과 상보성을 먼저 측정함으로써 얻은 음성 결과이다.

참고문헌

[1] J. R. Rice, “The Algorithm Selection Problem,” Advances in Computers, vol. 15, pp. 65–118, 1976.

[2] P. Kerschke, H. H. Hoos, F. Neumann, and H. Trautmann, “Automated Algorithm Selection: Survey and Perspectives,” Evolutionary Computation, vol. 27, no. 1, pp. 3–45, 2019.

[3] I. Ong et al., “RouteLLM: Learning to Route LLMs with Preference Data,” arXiv preprint arXiv:2406.18665, 2024.

[4] Y. Geifman and R. El-Yaniv, “Selective Classification for Deep Neural Networks,” in Advances in Neural Information Processing Systems (NeurIPS), 2017.

[5] Y. Geifman and R. El-Yaniv, “SelectiveNet: A Deep Neural Network with an Integrated Reject Option,” in International Conference on Machine Learning (ICML), 2019.

[6] A. Laurentini, “The Visual Hull Concept for Silhouette-Based Image Understanding,” IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 16, no. 2, pp. 150–162, 1994.

[7] Y. Li et al., “TripoSG: High-Fidelity 3D Shape Synthesis using Large-Scale Rectified Flow Models,” arXiv preprint arXiv:2502.06608, 2025.

[8] R. Li, C. Dumery, B. Guillard, and P. Fua, “Garment Recovery with Shape and Deformation Priors,” in IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2024.

[9] L. Mescheder, M. Oechsle, M. Niemeyer, S. Nowozin, and A. Geiger, “Occupancy Networks: Learning 3D Reconstruction in Function Space,” in IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019.

[10] C. Reiser et al., “Binary Opacity Grids: Capturing Fine Geometric Detail for Mesh-Based View Synthesis,” arXiv preprint arXiv:2402.12377, 2024.